

DIPLOMADO EN ECONOMETRÍA Y MACHINE
LEARNING APLICADO AL MERCADO FINANCIERO
V1

**Pronóstico de la tasa de variación interanual del IPC de
Bolivia con métodos de aprendizaje automático**

Taller para la elaboración del trabajo

Docente: Horacio Villegas Quino

Alumno: Ana Carolina Cladera Melgar

Bolivia

Abril de 2025

Contenido

1. Introducción	3
2. Revisión bibliográfica	4
3. Metodologías	5
3.1 Datos	5
3.2 Correlación de variables	7
3.3 Validación de modelos	10
3.4 Modelos	11
Modelo Arima	11
Modelo Prophet	11
Modelo Random Forest	12
Modelo Support Vector Regression (SVR)	13
3.5 Criterios de evaluación	13
Correlación de errores de pronóstico	14
Precisión del pronóstico	14
Varianza del error de pronóstico	14
4. Resultados	15
Insensamiento del Pronóstico (Unbiasedness)	15
Correlación de errores de pronóstico	16
Precisión del pronóstico	16
Varianza del error de pronóstico	19
5. Conclusiones	21
Referencias bibliográficas	22

1. Introducción

La predicción de la inflación desempeña un rol fundamental en la planificación económica y en la definición de políticas públicas, particularmente en países en desarrollo como Bolivia. La tasa de variación interanual del Índice de Precios al Consumidor (IPC) se utiliza ampliamente como indicador del comportamiento de los precios y del poder adquisitivo a lo largo del tiempo. Desde 2007, Bolivia ha atravesado importantes transformaciones en su política monetaria y cambiaria, lo que subraya la importancia de disponer de modelos de pronóstico más precisos y ajustados a las particularidades de su economía.

Tradicionalmente, métodos como el modelo ARIMA han sido ampliamente empleados para la predicción de series de tiempo económicas. Sin embargo, estudios recientes han demostrado que las técnicas de aprendizaje automático, como Random Forest y Support Vector Regression (SVR), pueden superar a los modelos econométricos clásicos, capturando relaciones no lineales y patrones complejos presentes en los datos. Asimismo, modelos como Prophet han ganado relevancia por su flexibilidad en la descomposición de tendencias y estacionalidades.

Ante la necesidad de contar con herramientas de predicción más sólidas, este estudio se propone comparar el desempeño de modelos econométricos tradicionales y técnicas de aprendizaje automático en la estimación de la inflación en Bolivia. El análisis no solo busca medir su precisión, sino también destacar las fortalezas y debilidades de cada enfoque en diferentes horizontes de corto, mediano y largo plazo.

El trabajo utiliza un esquema de validación *Rolling Origin Multi-Horizonte* y considera variables macroeconómicas relevantes para el contexto boliviano, siguiendo las recomendaciones de la literatura reciente. De esta forma, se espera aportar evidencia sobre la aplicabilidad de nuevas metodologías en el análisis económico del país.

2. Revisión bibliográfica

Predecir el índice de precios al consumidor (IPC) en Bolivia es crucial para entender la dinámica de la inflación, particularmente después de 2007, cuando las tasas de inflación se dispararon debido a las presiones externas y a los cambios en la política monetaria. El 2007 fue un periodo significativo, ya que marca un cambio en la política cambiaria de Bolivia destinada a estabilizar la moneda nacional y controlar la inflación, que se había visto exacerbada por la inflación importada y el aumento de los precios internacionales de los alimentos (Vargas, 2009) (Coria, 2014).

Además, se ha fortalecido la relación entre la inflación y la producción económica. Las expectativas de inflación se han establecido más en los últimos años previos, reflejando la política monetaria del Banco Central (Barrenechea, 2021) (Barrenechea et al., 2018). Por lo tanto, las predicciones precisas del IPC son esenciales para una planificación económica y una formulación de políticas eficaces en Bolivia.

Diversos estudios han evidenciado que los métodos de predicción basados en técnicas modernas, como los árboles de decisión y los bosques aleatorios, superan en desempeño a modelos econométricos tradicionales como ARIMA, lo que sugiere que estas técnicas avanzadas pueden captar mejor las complejidades de la dinámica de la inflación en las economías emergentes (Herrera, 2024).

El estudio de Bolívar (2024) introduce una innovadora metodología de aprendizaje automático de dos pasos para pronosticar las tasas de inflación semanales en Bolivia, utilizando datos desde 2019 hasta 2023. La metodología comienza entrenando algoritmos en datos de inflación mensual y luego aplicando estos modelos para generar pronósticos semanales. Este enfoque es relevante, debido a la escasez de datos económicos de alta frecuencia en los mercados emergentes, permitiendo generar predicciones más detalladas y adecuadas que mejoran la toma de decisiones económicas ante cambios abruptos y crisis. La eficacia del modelo fue notable, especialmente en períodos de crisis económica, superando modelos econométricos tradicionales en términos de precisión predictiva, lo que resalta la importancia de adaptar estrategias de análisis en entornos con limitaciones de datos.

Contribuciones como las de Zurita (2024), examinan la efectividad de distintos modelos de predicción del Índice de Precios al Consumidor (IPC) en Bolivia, comparando enfoques tradicionales como el modelo ARIMA con técnicas de aprendizaje automático, específicamente Árbol de Decisión, Árbol Podado y Random Forest. Los resultados demuestran que los modelos de aprendizaje automático, especialmente el Árbol Podado, superan al ARIMA en precisión, evidenciado por un menor error cuadrático medio de raíz (RMSE) de 0.0079 frente a 0.0376 del modelo convencional. Se subraya la importancia de considerar metodologías alternativas en el análisis económico debido a la volatilidad del IPC. Además, se recomienda la exploración de modelos híbridos y el uso de series temporales avanzadas, como redes neuronales, para mejorar aún más la precisión en las predicciones. La investigación brinda un marco valioso que no sólo contribuye al entendimiento económico boliviano, sino que también sugiere aplicaciones en otros contextos latinoamericanos.

Por último, el estudio de Rodríguez (2024) sobre el pronóstico de la inflación en Costa Rica explora la eficacia de diferentes métodos de Machine Learning en la predicción de la tasa de variación interanual del índice de precios al consumidor (IPC). Utilizando un enfoque de "rolling origin (multi horizonte)" para evitar problemas de data leakage y asegurar la validez de las predicciones. El estudio compara varias técnicas, incluyendo K-vecinos más cercanos (KNN), bosques aleatorios, incremento extremo de gradiente y redes neuronales de largo corto plazo (LSTM). Los resultados indican que los modelos LSTM y KNN univariantes logran el mejor rendimiento en términos de precisión y capacidad predictiva. Esta investigación se basará en este trabajo, aplicando el mismo esquema de validación "rolling origin (multi horizonte)" para explorar y comparar otros modelos de Machine Learning que no fueron considerados, como las máquinas de soporte vectorial (SVM), modelo Prophet de Meta, tanto univariado como multivariado con el objetivo de probar diferentes metodologías para predecir la tasa de variación interanual del Índice de precios al consumidor, en este caso usando datos de Bolivia.

3. Metodologías

3.1 Datos

- **Fuente de los datos**

El presente estudio se basa en un conjunto de datos compuesto por series temporales mensuales correspondientes a la economía boliviana, abarcando el período comprendido entre enero de 2007 y febrero de 2025. La base de datos contiene aproximadamente 218 observaciones. Las fuentes utilizadas incluyen el Instituto Nacional de Estadística (INE), el Banco Central de Bolivia (BCB), el Banco Mundial y la Reserva Federal de Estados Unidos (FED).

- **Variable objetivo**

La variable dependiente seleccionada es la tasa de variación interanual del Índice de Precios al Consumidor (IPC), publicada por el Instituto Nacional de Estadística (INE) de Bolivia. Esta medida refleja el cambio porcentual en el nivel de precios respecto al mismo mes del año anterior. Su uso es común en estudios económicos porque permite comparar niveles de inflación eliminando los efectos estacionales que afectan las variaciones mensuales, facilitando así un análisis más robusto y comparable en el tiempo (INE, 2023; Banco Mundial, 2022). Además, esta transformación es ampliamente empleada en análisis de política monetaria y predicción de inflación, tanto a nivel local como internacional (Rocha & Blanco, 2012; Carrillo-Maldonado & Díaz-Cassou, 2023).

- **Selección y clasificación de variables explicativas**

La selección de variables se basó en la literatura económica que identifica los principales determinantes de la inflación en países en desarrollo, particularmente en Bolivia. De acuerdo con estudios previos (Rocha & Blanco, 2012; Carrillo-Maldonado & Díaz-Cassou, 2023; Valdivia, 2014), se agruparon las variables en cuatro grandes bloques:

Tipo de cambio e inflación: Este grupo incluye variables vinculadas a la dinámica cambiaria, como el tipo de cambio oficial promedio, cuya influencia sobre los precios

internos se manifiesta a través de los precios de los bienes importados. En Bolivia, diversos estudios han demostrado que la depreciación del tipo de cambio puede generar presiones inflacionarias, especialmente en economías con alta dependencia de importaciones (Rocha & Blanco, 2012; Coria, 2014).

Choques externos y precios internacionales: Este grupo agrupa variables relacionadas con el entorno económico global, tales como el precio del petróleo, los precios de las materias primas agrícolas, la tasa Prime de la Reserva Federal y la inflación en socios comerciales como Brasil y China. Estas variables afectan la inflación interna mediante canales como el comercio exterior y la transmisión financiera (Carrillo-Maldonado & Díaz-Cassou, 2023; Martínez, 2023).

Políticas fiscales y monetarias: Este grupo comprende variables representativas de la política monetaria y fiscal implementadas por el Estado, tales como la base monetaria, el agregado monetario M1, las tasas de interés domésticas (TEA de reporto, tasa pasiva promedio) y el crédito al sector privado. Estas herramientas son fundamentales para gestionar la liquidez, el consumo y la inversión, con efectos directos sobre la dinámica inflacionaria (Cernadas, 2009; Coria & Coria, 2017; Valdivia, 2014).

Indicadores estructurales y de expectativas: Este grupo incluye variables que reflejan el comportamiento estructural de la economía y la percepción futura de los agentes económicos, como el índice global de actividad económica (IGAE), el salario mínimo nacional y las encuestas de expectativas inflacionarias publicadas por el BCB. Estas variables capturan la brecha del producto, los costos laborales y la formación de expectativas. Estudios previos han destacado la importancia de estas variables en la economía boliviana (Barrenechea, 2021) y en otros contextos económicos (Anghel et al., 2018).

A continuación, se presenta una tabla con la clasificación de cada variable

Variable	Descripción	Fuentes
TCN	Tasa de variación interanual del tipo de cambio oficial	Instituto Nacional de Estadística (INE)
PETRO	Tasa de variación interanual del precio del petróleo Brent/WTI	Banco Mundial
GRANOS	Tasa de variación interanual del índice de precios agrícolas	Banco Mundial
PRIMERATE	Prime Rate de la FED (mensual)	Reserva Federal de Estados Unidos (FED)
INFSOC_BR INFSOC_CH	Tasa de variación interanual de la Inflación de socios comerciales (Inflación de Brasil y China (interanual))	Oficina Nacional de Estadística de China (NBOS), Instituto Brasileño de Geografía y Estadística (IBGE), Banco Mundial
BASEM	Tasa de variación interanual de la base monetaria	Banco Central de Bolivia (BCB)

M1	Tasa de variación interanual del agregado monetario M1	Banco Central de Bolivia (BCB)
TPM	Tasa efectiva anualizada de reporto en moneda nacional	Banco Central de Bolivia (BCB)
TBP	Tasa promedio pasiva del sistema financiero	Banco Central de Bolivia (BCB)
CREDPRIVSF	Tasa de variación interanual del crédito privado	Banco Central de Bolivia (BCB)
EXPINF12	Expectativas de inflación (12 meses, BCB)	Banco Central de Bolivia (BCB)
IGAETC	Tasa de variación interanual del IGAE (ciclo-tendencia)	Instituto Nacional de Estadística (INE)
ISMNNIV	Tasa de variación interanual del salario mínimo nacional	Instituto Nacional de Estadística (INE)
IPC	Tasa de variación interanual del Índice de precios al consumidor	Instituto Nacional de Estadística (INE)

- **Transformaciones, rezagos y variables dummies**

Las variables explicativas fueron transformadas en tasas de variación interanual cuando fue pertinente, con el fin de estandarizar escalas y eliminar tendencias.

Se generaron 12 rezagos para cada variable con el fin de capturar efectos retardados que podrían influir en la inflación (IPC). Esta estrategia busca reflejar la persistencia de las variables macroeconómicas, ya que los valores históricos suelen impactar en el comportamiento económico actual y futuro (Enders, 2004; Stock & Watson, 2001). La inclusión de múltiples rezagos permite al modelo identificar relaciones dinámicas en distintos plazos.

Asimismo, se incorporaron variables dummy para capturar efectos estacionales, lo que ayuda a mejorar la especificación del modelo y a reducir posibles errores derivados de la estacionalidad (Harvey, 1990).

Finalmente, estas variables y sus rezagos fueron integradas en un único dataset multivariado que sirve como insumo principal para la estimación de modelos econométricos y de aprendizaje automático orientados a la predicción de la inflación en Bolivia.


3.2 Correlación de variables

La etapa del análisis de correlación es fundamental en la exploración de datos, ya que permite cuantificar la dirección y la fuerza de la relación lineal entre dos variables cuantitativas.

Coeficiente de correlación de Pearson

Para realizar el análisis de correlación entre las variables, se utilizó el coeficiente de correlación de Pearson. Este coeficiente varía entre los valores -1 y 1, donde, un valor cercano a 1 indica una fuerte relación lineal positiva, es decir, a medida que una variable aumenta, otra tiende a aumentar; mientras que un valor cercano a -1 señala una fuerte relación lineal negativa, donde el incremento en una variable coincide con la disminución de otra. Un valor alrededor de 0 indica la ausencia de una relación lineal significativa. La elección del coeficiente de Pearson se fundamenta en los principios establecidos por Pearson (1895), lo cual ha sido ampliamente validado en estudios estadísticos y econométricos para la determinación de relaciones lineales entre variables.

Además, se generó una matriz de correlación y se visualizó mediante un mapa de calor para identificar de manera intuitiva las asociaciones más destacadas.



Se analizó la matriz de correlación para evaluar la relación lineal entre el IPC y las variables independientes.

Los principales hallazgos son:

- **Expectativas de inflación (EXPINF12)** muestra una correlación positiva alta con el IPC (0.9), indicando una fuerte relación directa.

- **Tipo de cambio (TCN)** presenta una correlación negativa significativa (-0.71) con el IPC, sugiriendo que una depreciación cambiaria podría estar asociada a un menor crecimiento del IPC.
- **Índice de actividad económica (IGAETC)** y **base monetaria (BASEM)** también presentan correlaciones positivas moderadas con el IPC.
- El resto de las variables, como tasas de interés (**TPM**, **TBP**) y precios internacionales (**PETRO**, **GRANOS**), muestran correlaciones más débiles.
- Se observan **altas correlaciones internas** entre algunas variables monetarias (**BASEM** y **M1**, correlación 0.98), lo que podría indicar riesgo de multicolinealidad en modelos multivariados.

Estos resultados respaldan la selección de **EXPINF12**, **TCN**, y **IGAETC** como variables clave para la predicción del IPC.

Análisis exploratorio de relaciones bivariadas

Para evaluar la relación entre la tasa de variación interanual del IPC y cada una de las variables predictoras, se ha utilizado gráficos de dispersión. Esta técnica permite visualizar cómo se comporta la variable dependiente en función de los diferentes predictores, identificando patrones de relación lineal o no lineal.

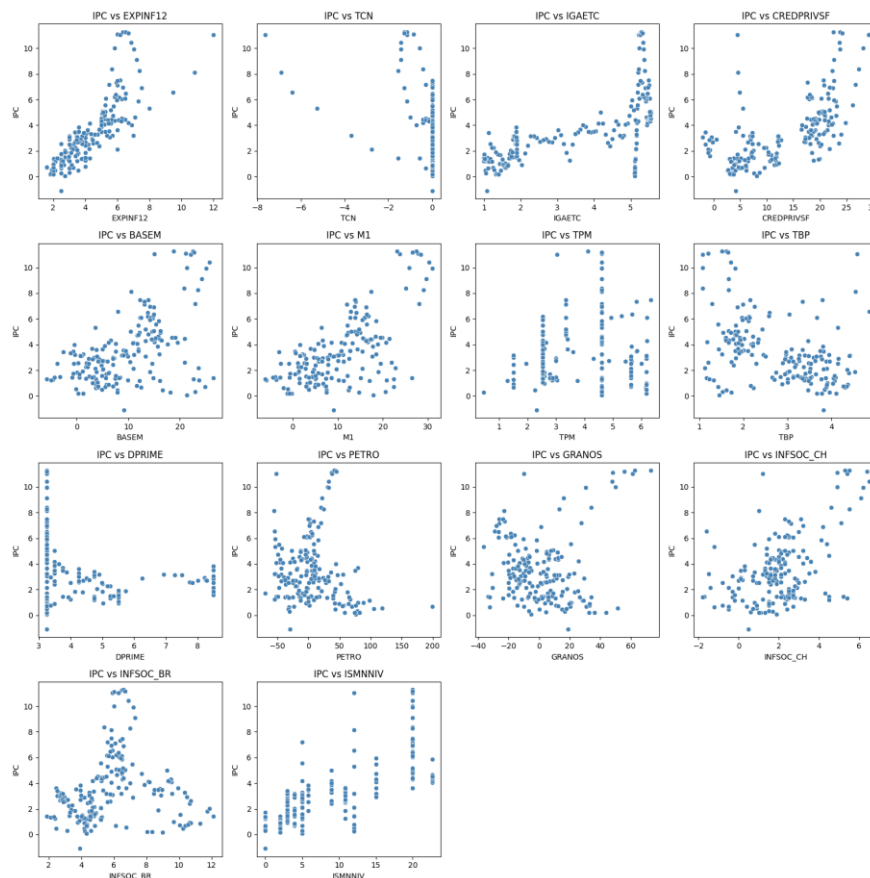


Ilustración 1 Gráficos de Dispersión

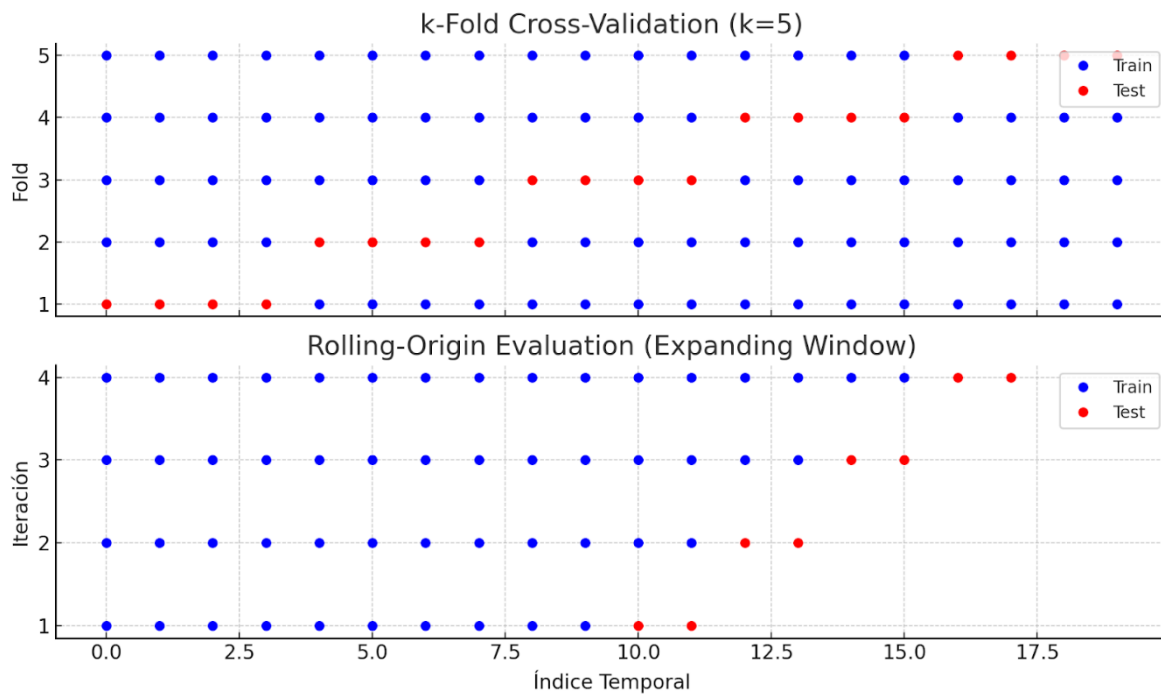
Se exploraron las relaciones bivariadas entre el IPC y las variables explicativas mediante diagramas de dispersión. Se observan asociaciones positivas destacadas en expectativas de inflación e índice de actividad económica, mientras que otras variables muestran relaciones más débiles o dispersas. También se detectaron patrones no lineales y algunos valores extremos.

3.3 Validación de modelos

Rolling Origin Evaluation

Rolling Origin Evaluation es una técnica que respeta la secuencia temporal, es utilizada para validar modelos de series de tiempo. Esta técnica realiza las predicciones luego de haber entrenado el modelo hasta una fecha específica y luego avanza en el tiempo con el conjunto de entrenamiento, repitiendo el proceso. (Tashman, 2000)

La imagen compara k-Fold Cross-Validation y Rolling-Origin Evaluation. Mientras el k-Fold divide los datos aleatoriamente, Rolling-Origin respeta el orden temporal expandiendo progresivamente el conjunto de entrenamiento, lo cual es más apropiado para series de tiempo.



Rolling Origin Multi-Horizonte en series de tiempo

Una extensión de esta metodología es el Rolling Origin Multi-Horizonte, donde no se realiza una única predicción futura, sino que se estiman varios horizontes de pronóstico de manera simultánea. Es decir, para cada punto de corte, se generan predicciones a X meses adelante, permitiendo evaluar el desempeño del modelo en diferentes plazos temporales.

En el presente trabajo, se aplicó este tipo de validación sobre la serie mensual de la tasa de variación interanual del IPC de Bolivia, evaluando los modelos para horizontes de 1, 3, 6 y 12 meses, tanto en enfoques univariados como multivariados.

3.4 Modelos

Modelo Arima

El modelo ARIMA (Auto Regressive Integrated Moving Average) es una de las herramientas más reconocidas para analizar y predecir series temporales univariadas. Propuesto por Box y Jenkins en 1970, este método se basa en representar la evolución de una serie como una combinación de sus propios valores pasados (parte autorregresiva, AR), los errores cometidos en predicciones anteriores (componente de media móvil, MA) y, si es necesario, aplicando diferenciaciones sucesivas para lograr que la serie sea estacionaria (parte integrada, I) (Box & Jenkins, 1970).

En su forma general, un modelo ARIMA(p,d,q) representa una serie temporal donde:

p es el número de rezagos autorregresivos.

d es el número de diferenciaciones necesarias para alcanzar estacionariedad.

q es el número de rezagos de los errores en la parte de media móvil.

Particularmente este tipo de modelo es útil cuando la serie presenta patrones de dependencia temporal y tendencia, pero no requiere variables exógenas.

En este estudio, se utilizará un modelo ARIMA(1,1,2) como enfoque econométrico base, el cual será evaluado y comparado con modelos modernos de aprendizaje automático bajo un mismo esquema de predicción para la inflación interanual en Bolivia. La estructura del modelo fue determinada tras realizar un análisis de autocorrelación (ACF) y autocorrelación parcial (PACF), y luego validada mediante pruebas de estacionariedad y comparaciones de desempeño.

Modelo Prophet

El modelo Prophet fue creado en 2017 por investigadores de Facebook (ahora Meta) con el objetivo de proporcionar una herramienta sencilla y efectiva para realizar pronósticos de series temporales. Se basa en una estructura aditiva que divide la serie en tres componentes principales: tendencia, estacionalidad y efectos de eventos especiales (Taylor & Letham, 2018).

La componente de tendencia permite capturar cambios de dirección en momentos específicos, conocidos como puntos de cambio. La estacionalidad, por su parte, se modela mediante funciones periódicas que representan patrones repetitivos, como variaciones anuales. Además, Prophet ofrece la posibilidad de incorporar eventos particulares, como feriados o fechas económicas relevantes. Una de sus principales fortalezas es su robustez frente a datos faltantes o la presencia de valores atípicos, una situación frecuente en análisis económicos.

En estudios del área económica, Prophet ha sido aplicado en la predicción de variables como el Índice de Precios al Consumidor (IPC) y el Producto Interno Bruto (PIB). Şengüler y Kara (2025) utilizaron este modelo para estimar la inflación en Turquía, aprovechando su flexibilidad para adaptarse a cambios de tendencia y estacionalidad en los datos. De manera similar, Kolari y Sanz (2022) emplearon Prophet para proyectar indicadores financieros relacionados con el crecimiento económico, demostrando su utilidad cuando se incorporan variables explicativas adicionales.

- **Univariado**

En el primer enfoque, se utilizó Prophet de manera univariada, considerando únicamente la información histórica del IPC. El modelo fue configurado para capturar cambios de tendencia mediante un ajuste de los puntos de cambio, controlados a través de parámetros específicos que regulan la flexibilidad de la tendencia y la estacionalidad.

- **Multivariado**

En una segunda etapa, se ajustó Prophet en un enfoque multivariado, incorporando como regresores externos variables macroeconómicas relevantes para el comportamiento del IPC. Este enfoque permitió enriquecer las predicciones considerando factores adicionales, manteniendo la estructura aditiva del modelo y aprovechando su capacidad para integrar múltiples fuentes de información.

Modelo Random Forest

El modelo Random Forest fue desarrollado por Leo Breiman en 2001, es una técnica de ensamblaje que aborda problemas de predicción supervisada combinando múltiples árboles de decisión. Cada árbol es entrenado de manera independiente utilizando una muestra aleatoria de los datos originales y un subconjunto aleatorio de variables en cada división, lo que permite capturar relaciones complejas y no lineales. La predicción final se obtiene promediando las salidas individuales en tareas de regresión, lo cual ayuda a reducir la varianza y mejora la capacidad de generalización del modelo, disminuyendo así el riesgo de sobreajuste (Breiman, 2001).

En el ámbito económico, Random Forest ha demostrado ser una herramienta efectiva para predecir variables como el Índice de Precios al Consumidor (IPC), el Producto Interno Bruto (PIB) y tasas de interés. Su habilidad para manejar múltiples predictores y modelar relaciones no lineales le ha permitido superar en desempeño a métodos econométricos tradicionales en varios estudios. Investigaciones recientes, como las de Araujo y Gaglianone (2020) y Kolari y Sanz (2022), destacan su capacidad para adaptarse a entornos donde los datos presentan alta complejidad y comportamientos difíciles de capturar mediante modelos lineales convencionales.

En esta investigación, el modelo Random Forest fue configurado con una profundidad máxima de 5 niveles, seleccionando las variables en cada división según el logaritmo en base dos del número total de predictores y utilizando 50 árboles en su construcción. Los valores de los hiperparámetros fueron definidos tras evaluar diferentes configuraciones posibles, priorizando aquellas que ofrecieran un mejor desempeño predictivo, respetando la secuencia temporal de los datos.

Modelo Support Vector Regression (SVR)

El modelo de regresión basado en máquinas de vectores de soporte (Support Vector Regression, SVR) deriva de las técnicas introducidas por Vapnik en 1995, y está orientado a resolver problemas de predicción de valores continuos en el ámbito del aprendizaje automático. A diferencia de los modelos de clasificación, SVR busca construir una función que aproxime los valores reales dentro de un margen de tolerancia predefinido, priorizando además la simplicidad del modelo para mejorar su capacidad de generalización.

En el campo económico, SVR ha sido utilizado para anticipar variables macroeconómicas como el Índice de Precios al Consumidor (IPC), mostrando un desempeño sólido en situaciones donde las relaciones entre variables son no lineales y los datos manejan alta dimensionalidad (Patel et al., 2015; Wang et al., 2018). Estos estudios destacan su efectividad, sobre todo en horizontes de predicción de corto y mediano plazo.

El algoritmo se basa en la utilización de funciones kernel, las cuales transforman los datos de entrada en espacios de mayor dimensión para identificar patrones complejos. Los parámetros básicos que configuran el modelo incluyen:

C = el parámetro de regularización, que controla la penalización de los errores,

ϵ = el parámetro de tolerancia al error y

γ = el parámetro que define la forma del kernel, conocido como gamma.

En esta investigación, los hiperparámetros fueron seleccionados mediante una exploración de combinaciones predefinidas, evaluando distintas configuraciones posibles, adaptada a la estructura temporal de los datos. Como resultado de este procedimiento, se seleccionó la combinación de valores de regulación igual a 1, tolerancia al error igual a 0.5 y gamma configurado como escala automática, lo que permitió minimizar el error cuadrático medio en los distintos horizontes de predicción considerados.

3.5 Criterios de evaluación

Insesgamiento del Pronóstico (Unbiasedness)

El insesgamiento en los modelos de predicción se refiere a su capacidad para generar estimaciones que no tiendan sistemáticamente a sobrestimar ni subestimar los valores reales. En otras palabras, un modelo insesgado produce errores de predicción distribuidos de forma equilibrada alrededor de los datos observados (Tashman, 2000).

Este criterio es especialmente relevante en el contexto de pronósticos económicos, dado que la presencia de sesgos puede distorsionar decisiones importantes, como las relacionadas con política monetaria, planificación presupuestaria o gestión de riesgos. Para evaluar el insesgamiento, se estima una regresión entre los valores reales y las predicciones: se considera que el modelo cumple con esta propiedad cuando el intercepto no es significativamente distinto de cero y la pendiente se aproxima a uno (Diebold, 2015).

De acuerdo con Mincer y Zarnowitz (1969), esta evaluación se realiza modelando el valor observado como una función lineal del valor pronosticado, verificando que el intercepto sea igual a cero y el coeficiente de la variable independiente sea igual a uno.

En el análisis realizado, se aplicaron pruebas de insesgamiento a los modelos evaluados, siguiendo los procedimientos sugeridos en investigaciones anteriores.

Correlación de errores de pronóstico

El análisis de la correlación de errores de pronóstico busca determinar si los errores generados por un modelo están autocorrelacionados, ya que la presencia de patrones no capturados puede indicar una especificación inadecuada del modelo.

Al examinar estos errores, es crítico considerar el horizonte de predicción. Según Diebold y López (1996), cuando el horizonte es de un solo periodo ($h = 1$), se espera que los errores se comporten como ruido blanco, es decir, de forma independiente y sin autocorrelación. En cambio, para horizontes más amplios ($h > 1$), los errores tienden a seguir un proceso de media móvil de orden $h-1$ ($MA(h-1)$), permitiendo la existencia de correlaciones hasta $h-1$ rezagos.

Para verificar estas propiedades, se recomienda utilizar pruebas específicas. En horizontes de un paso $h = 1$, Dufour (1981) propuso una versión modificada de la prueba de Wilcoxon para detectar autocorrelación. Para horizontes mayores, Cumby y Huizinga (1992) desarrollaron una prueba que permite comprobar si los errores siguen un proceso $MA(q)$ con el orden esperado. Estas pruebas son esenciales para garantizar que los errores de pronóstico no exhiban patrones sistemáticos que puedan comprometer la fiabilidad de las predicciones.

Precisión del pronóstico

La precisión de los modelos de pronóstico se evalúa mediante métricas como el Error Cuadrático Medio (RMSE) y el coeficiente de desigualdad de Theil. El RMSE cuantifica el error promedio cometido por el modelo, mientras que el coeficiente de Theil compara el desempeño del modelo frente a una estrategia de predicción básica.

Se recurre a la prueba de Diebold-Mariano en su versión ajustada por Harvey, Leybourne y Newbold (1997) para determinar si las diferencias de precisión entre modelos son estadísticamente significativas. Esta prueba ofrece mayor robustez ante posibles problemas de autocorrelación en los errores o tamaño de muestra reducidos.

Además del tamaño del error, resulta esencial valorar si el modelo es capaz de anticipar correctamente los cambios en la dirección de la variable, como prever incrementos o caídas. Esta habilidad para detectar puntos de giro es particularmente relevante en contextos económicos, donde identificar cambios de tendencia puede ser tan crítico como predecir niveles exactos (Harvey, Leybourne & Newbold, 1997).

Varianza del error de pronóstico

La varianza del error de pronóstico refleja la dispersión de los errores en torno a su media, y constituye un indicador clave del nivel de incertidumbre asociado a las predicciones.

Según Pesaran y Shin (1998), un modelo robusto debería generar errores con baja varianza, ya que esto sugiere mayor estabilidad y confiabilidad en los resultados.

Más allá de evaluar la magnitud de la dispersión, también es importante examinar cómo varía la varianza de los errores a medida que se incrementa el horizonte de predicción, aspecto esencial en la validación de modelos en diferentes plazos.

En este contexto, Diebold y López (1996) plantean que en un modelo bien especificado, la varianza de los errores debería crecer o, al menos, mantenerse constante conforme se pronostican periodos más lejanos, debido al aumento natural de la incertidumbre. Para verificar este comportamiento, se utilizan pruebas F que comparan las varianzas entre distintos horizontes de predicción. Una disminución de la varianza al aumentar el horizonte podría señalar deficiencias en la especificación del modelo o una subestimación del riesgo futuro.

4. Resultados

Insesgamiento del Pronóstico (Unbiasedness)

La verificación del in sesgamiento en los pronósticos se llevó a cabo utilizando la prueba sugerida por Mincer y Zarnowitz (1969).

Modelos	h=1	h=3	h=6	h=12
Random Forest	0.025040	0.002759	0.000413	0.000996
ARIMA(1,1,2)	0.055556	0.000467	0.000712	0.001873
SVR	0.030992	0.371748	0.028828	0.261366
Prophet Multivariado	0.183566	0.000000	0.000000	0.000000
Prophet Univariado	0.000000	0.000000	0.000000	0.000000

El modelo ARIMA (1,1,2) no presentó sesgo para el horizonte de un mes ($h=1$), pero sí para horizontes mayores ($h=3$, $h=6$ y $h=12$). El modelo Random Forest exhibió sesgo en todos los horizontes analizados, indicando que sus pronósticos tienden a sobrestimar o subestimar sistemáticamente el valor real. El modelo SVR cumplió con la propiedad de unbiasedness en los horizontes $h=3$ y $h=12$, pero mostró sesgo en $h=1$ y $h=6$. El modelo Prophet Multivariado cumplió la condición de unbiasedness únicamente en $h=1$, siendo sesgado en horizontes más largos. Finalmente, el Prophet Univariado presentó sesgo sistemático en todos los horizontes considerados.

Estos resultados sugieren que, si bien algunos modelos son capaces de producir pronósticos no sesgados en el corto plazo, la mayoría tiende a presentar sesgos a medida que el horizonte de predicción se extiende.

Correlación de errores de pronóstico

Siguiendo el enfoque planteado por Diebold y López (1996), se empleó el test de Wilcoxon-Dufour (1981) para analizar la autocorrelación de primer orden ($h=1$), y la prueba de Cumby y Huizinga (1992) para evaluar horizontes más amplios ($h=3, 6$ y 12), utilizando como referencia práctica el test de Ljung-Box.

Los resultados de los p-valores obtenidos se resumen en la siguiente tabla:

Modelo	h=1	h=3	h=6	h=12
Random Forest	0.007690	0.008139	0.032103	0.029632
SVR	0.043167	0.000997	0.045329	0.014043
ARIMA(1,1,2)	0.088371	0.000000	0.000000	0.000000
Prophet Multivariado	0.155668	0.000000	0.000000	0.000000
Prophet Univariado	0.000000	0.001095	0.059522	0.000000

El modelo ARIMA (1,1,2) cumple la hipótesis de ausencia de autocorrelación únicamente para el horizonte de un mes ($h=1$), pero presenta autocorrelación significativa para horizontes más largos. Prophet Multivariado también cumple en $h=1$, pero falla en todos los horizontes posteriores. Random Forest y SVR no cumplen la propiedad de errores no correlacionados en ningún horizonte, lo que sugiere que estos modelos, a pesar de su flexibilidad, no logran capturar completamente la dinámica subyacente del IPC. Prophet Univariado presenta un comportamiento mixto: no cumple para $h=1$ ni para horizontes largos, pero curiosamente cumple para $h=6$, lo que podría deberse a una coincidencia estadística más que a una propiedad estructural del modelo.

Estos resultados indican que la mayoría de los modelos presentan autocorrelación significativa en los errores de pronóstico, particularmente en horizontes de predicción de mediano y largo plazo ($h=3, h=6, h=12$).

Esto sugiere que los modelos podrían no estar capturando completamente la dinámica del IPC o que persisten patrones sistemáticos en los errores que podrían ser aprovechados por modelos más sofisticados o mediante correcciones adicionales.

Precisión del pronóstico

- RMSE

El RMSE (Root Mean Squared Error) fue utilizado como métrica principal para evaluar la precisión de los pronósticos generados por los distintos modelos, un menor valor de

RMSE implica un mejor desempeño en términos de precisión de pronóstico según la metodología planteada por Harvey et al. (1997)

Los resultados obtenidos se muestran en la tabla:

Horizonte	1	3	6	12
Modelo				
ARIMA(1,1,2)	0.557233	1.416624	2.713867	4.114830
Prophet Multivariado	0.389769	0.777154	0.968838	1.547676
Prophet Univariado	2.277335	2.445509	2.888316	5.449473
Random Forest	0.517745	0.681857	0.827701	0.774920
SVR	0.919396	0.745795	0.633172	0.55318

El modelo Prophet Multivariado logra el RMSE más bajo en el corto plazo ($h=1$), destacándose como el más preciso para predicciones a un mes. En el horizonte de tres meses ($h=3$), el modelo Random Forest supera a los demás modelos, obteniendo la mejor precisión. Para horizontes de seis y doce meses ($h=6$ y $h=12$), el modelo SVR presenta el menor RMSE, indicando una mayor estabilidad en el mediano y largo plazo. Los modelos ARIMA (1,1,2) y Prophet Univariado presentan un desempeño significativamente inferior, con errores más elevados en todos los horizontes analizados.

El análisis basado en RMSE evidencia que los modelos de aprendizaje automático (Random Forest y SVR) y Prophet Multivariado ofrecen ventajas comparativas en la predicción del IPC, especialmente a medida que el horizonte de pronóstico se amplía, mientras que los modelos tradicionales presentan limitaciones importantes en términos de precisión Encompassing tests

- Coeficiente de Theil

La comparación de la precisión entre modelos se realizó a través del coeficiente de desigualdad de Theil (U), siguiendo el procedimiento establecido por Harvey et al. (1997). Este indicador permite contrastar el desempeño del modelo de pronóstico frente a un modelo Naive.

Los resultados se muestran en la tabla:

Horizonte	1	3	6	12
Modelo				
ARIMA(1,1,2)	0.773412	1.911572	3.544392	5.028987
Prophet Multivariado	0.959212	1.894377	1.790448	3.020519
Prophet Univariado	5.498770	5.803502	6.103310	6.791951

Random Forest	1.384809	1.777959	1.993243	1.954769
SVR	2.459102	1.944680	1.524785	1.395432

El modelo ARIMA (1,1,2) presenta el mejor desempeño en el muy corto plazo ($h=1$), mientras que SVR domina en los horizontes de mediano y largo plazo ($h=6$ y $h=12$). Random Forest se destaca en el horizonte de tres meses ($h=3$), superando a otros modelos de machine learning. En contraste, Prophet Univariado muestra un bajo desempeño en todos los horizontes, con coeficientes de Theil consistentemente superiores a uno. Finalmente, Prophet Multivariado mejora respecto a su versión univariada, aunque su precisión disminuye conforme aumenta el horizonte de predicción.

Estos resultados refuerzan la conclusión de que los modelos basados en machine learning, particularmente el SVR, ofrecen ventajas competitivas en la predicción de inflación a mediano y largo plazo, mientras que los modelos tradicionales y algunos métodos de series de tiempo requieren ajustes para mantener su precisión conforme se incrementa el horizonte de predicción.

- Dirección Correcta

Es una métrica que evalúa la capacidad de predicción de la dirección de cambio. La habilidad de los modelos para anticipar correctamente la dirección del cambio en la inflación fue evaluada mediante el porcentaje de cambios correctamente predichos.

Los resultados de la tabla muestran:

Horizonte	1	3	6	12
Modelo				
ARIMA(1,1,2)	0.666667	0.588235	0.516129	0.480000
Prophet Multivariado	0.607143	0.481928	0.550336	0.409692
Prophet Univariado	0.538462	0.500000	0.461538	0.538462
Random Forest	0.470588	0.588235	0.588235	0.235294
SVR	0.529412	0.411765	0.352941	0.529412

El modelo ARIMA (1,1,2) se destaca en el corto plazo ($h=1$), mientras que Random Forest presenta una sólida capacidad predictiva en los horizontes de tres y seis meses ($h=3$ y $h=6$). Para el horizonte de doce meses ($h=12$), SVR logra el mejor desempeño relativo. Aunque Prophet Multivariado muestra resultados aceptables en el corto y mediano plazo, su precisión disminuye en el largo plazo, mientras que Prophet Univariado mantiene un desempeño limitado en todos los horizontes.

Los resultados muestran que Random Forest y SVR destacan por su capacidad de anticipar cambios en la inflación en horizontes de mediano y largo plazo, mientras que ARIMA (1,1,2) sobresale en el corto plazo.

Varianza del error de pronóstico

Según lo planteado por Diebold y López (1996), bajo un criterio de pérdida cuadrática, la varianza de los errores de pronóstico debería mantenerse constante o incrementarse a medida que se extiende el horizonte, reflejando así el crecimiento natural de la incertidumbre.

- Tabla de varianzas

Los resultados de la tabla muestran que:

Modelo	h=1	h=3	h=6	h=12
Random Forest	0.183004	0.241312	0.405437	0.315812
ARIMA(1,1,2)	0.286070	1.563853	5.417230	12.456880
SVR	0.646704	0.525754	0.421683	0.306978
Prophet Multivariado	0.145633	0.533279	0.775262	1.219940
Prophet Univariado	1.023565	0.935794	0.850495	9.267840

El modelo ARIMA (1,1,2) muestra un aumento constante y claro en la varianza de los errores conforme se amplía el horizonte, en línea con lo esperado teóricamente. El Prophet Multivariado también presenta un incremento en la varianza, aunque con ciertas fluctuaciones intermedias. Por el contrario, Random Forest y SVR evidencian caídas en la varianza en algunos horizontes, lo que indica un incumplimiento parcial de la propiedad de no decrecimiento. Finalmente, el Prophet Univariado refleja un comportamiento irregular, pero alcanza un crecimiento evidente de la varianza en el horizonte de 12 meses.

- Tabla de F-tests

De acuerdo con el enfoque de Diebold y López (1996), se aplicaron pruebas F para analizar si existen diferencias significativas en las varianzas de los errores de pronóstico entre distintos horizontes.

Los resultados muestran que:

Modelo	h1_vs_h3	h1_vs_h6	h1_vs_h12	h3_vs_h6	h3_vs_h12	h6_vs_h12
Random Forest	0.574808	1.105594e-01	2.705538e-01	0.294477	5.852190e-01	6.122577e-01
ARIMA(1,1,2)	0.000002	3.204157e-14	9.624009e-20	0.000575	7.498619e-08	2.882632e-02
SVR	0.674295	3.867614e-01	1.344050e-01	0.654401	2.771866e-01	5.198206e-01

Prophet Multivariado	0.000258	3.188874e-06	1.163508e-08	0.061404	2.524731e-05	3.001503e-03
Prophet Univariado	0.820935	6.402196e-01	3.040649e-07	0.809325	1.164244e-07	4.110985e-08

El modelo ARIMA (1,1,2) evidencia un aumento progresivo y significativo de la varianza con el horizonte, mientras que Random Forest y SVR mantienen una varianza relativamente constante. El Prophet Multivariado presenta un incremento de la varianza al comparar horizontes cortos con largos, y el Prophet Univariado muestra un crecimiento marcado de la incertidumbre en el largo plazo.

5. Conclusiones

El presente estudio evaluó el desempeño de distintos modelos econométricos y de aprendizaje automático para el pronóstico de la tasa de variación interanual del Índice de Precios al Consumidor (IPC) en Bolivia. Se aplicaron metodologías como ARIMA (1,1,2), Prophet en sus versiones univariada y multivariada, Random Forest y Support Vector Regression (SVR), bajo un esquema de validación Rolling Origin Multi-Horizonte.

Los resultados muestran que los modelos de Machine Learning, en particular SVR y Random Forest, obtuvieron mejores desempeños en horizontes de mediano y largo plazo, mientras que el modelo ARIMA fue más efectivo en el corto plazo. Sin embargo, la mayoría de los modelos presentó problemas de sesgo y autocorrelación de errores a medida que aumentaba el horizonte de predicción.

Aunque se lograron avances, los resultados podrían mejorarse. Se recomienda realizar una búsqueda más amplia de hiperparámetros, probar otros métodos de procesamiento de datos y considerar la incorporación de más variables explicativas que reflejen mejor las dinámicas económicas del país.

Asimismo, sería valioso explorar la combinación de modelos, como integrar un modelo econométrico con uno de Machine Learning o utilizar dos modelos de Machine Learning en conjunto, para capturar de manera más precisa los diferentes patrones que afectan la inflación en Bolivia.

Finalmente, resulta fundamental ajustar las metodologías de pronóstico a las especificidades de la economía boliviana, integrando variables contextuales que reflejen adecuadamente sus características estructurales y dinámicas internas.

Referencias bibliográficas

Bolívar, O. (2024). Pronóstico semanal de inflación: una metodología de aprendizaje automático de dos pasos. Ministerio de Economía y Finanzas Públicas. <https://www.researchgate.net/publication/383174571>

Rodríguez-Vargas, A. (2020). Forecasting Costa Rican inflation with machine learning methods. *Latin American Journal of Central Banking*, 1, 100012. <https://doi.org/10.1016/j.latcb.2020.100012>

Barrenechea, M. M. (2021). Una revisión a la Curva de Phillips en Bolivia. *LAJED*, 35, 159-188.

Barrenechea, M. M., & otros. (2018). The Time-Varying Degree of Inflation Expectation Anchoring in Bolivia. *Research Papers in Economics*, julio 2005–junio 2017.

Coria, D. E. Z., & Vargas, D. de S. (2014). La política cambiaria en Bolivia: objetivos y efectividad. *Revista*, 23(2), 65-104.

Herrera, J. (2024). Evaluación de la precisión en el pronóstico de la inflación en Bolivia: random forest y árboles de decisión vs. arima. *Compás Empresarial*, 15(39), 52-80.

Enders, W. (2004). *Applied Econometric Time Series*. Wiley.

Harvey, A. C. (1990). *Forecasting, Structural Time Series Models and the Kalman Filter*. Cambridge University Press.

Stock, J. H., & Watson, M. W. (2001). Vector autoregressions. *Journal of Economic Perspectives*, 15(4), 101–115.

Anghel, L., Bălăceanu, C., & Stanciu, M. (2018). Inflationary process in Romania in the context of current macroeconomic trends. *Internal Auditing & Risk Management*, 13(1), 83-91.

Barrenechea, F. (2021). La Curva de Phillips en Bolivia: un análisis econométrico. *Revista de Estudios Económicos de Bolivia*.

Carrillo-Maldonado, R., & Díaz-Cassou, J. (2023). Boom, bust and beyond: Bolivia's growth story and prospects. *Inter-American Development Bank*.

Cernadas, J. (2009). Política fiscal e inflación en América Latina. *Revista CEPAL*.

Coria, M. (2014). Tipo de cambio y precios en Bolivia: una revisión empírica. *Documentos de Trabajo*, Banco Central de Bolivia.

Coria, M., & Coria, P. (2017). Análisis de la política monetaria en Bolivia: retos y perspectivas. *Banco Central de Bolivia*.

Martínez, C. (2023). Impacto de los precios internacionales sobre la economía boliviana. *Fundación Jubileo*.

Box, G. E. P., & Jenkins, G. M. (1970). *Time Series Analysis: Forecasting and Control*. San Francisco: Holden-Day.

Rocha, M., & Blanco, F. (2012). Inflation dynamics in Bolivia: The role of exchange rate and monetary policy. *Banco Central de Bolivia*.

Valdivia, M. (2014). Interacción entre política fiscal y monetaria en Bolivia. Documento de Trabajo, UMSA.

Instituto Nacional de Estadística (INE). (2023). Boletín estadístico mensual. Recuperado de: <https://www.ine.gob.bo>

Banco Mundial. (2022). Consumer Price Index for Bolivia. World Development Indicators. <https://data.worldbank.org>

Vapnik, V. (1995). The Nature of Statistical Learning Theory. Springer.

Patel, J., Shah, S., Thakkar, P., & Kotecha, K. (2015). Predicting stock market index using fusion of machine learning techniques. *International Journal of Computer Applications*, 123(1), 7-12.

Wang, J., Fang, J., & Xu, Z. (2018). Forecasting financial time series with support vector regression: A review. *International Journal of Forecasting*, 34(1), 65-86.

Taylor, S. J., & Letham, B. (2018). Forecasting at scale. *The American Statistician*, 72(1), 37–45. <https://doi.org/10.1080/00031305.2017.1380080>

Şengüler, H., & Kara, B. (2025). Forecasting the inflation for budget forecasters: An analysis of ANN model performance in Türkiye. (Artículo aceptado, Istanbul Medeniyet University).

Kolari, J. W., & Sanz, I. (2022). Forecasting bank capital ratios using the Prophet model by Facebook. *SSRN Electronic Journal*. <https://doi.org/10.2139/ssrn.4141575>

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>

Araujo, G. S., & Gaglianone, W. P. (2020). Machine learning methods for inflation forecasting in Brazil: New contenders versus classical models. Banco Central do Brasil, Working Paper Series No. 561.

Kolari, J. W., & Sanz, I. (2022). Forecasting bank capital ratios using the Prophet model by Facebook. *SSRN Electronic Journal*. <https://doi.org/10.2139/ssrn.4141575>

Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: an analysis and review. *International Journal of Forecasting*, 16(4), 437–450. [https://doi.org/10.1016/S0169-2070\(00\)00065-0](https://doi.org/10.1016/S0169-2070(00)00065-0)

Diebold, F. X. (2015). *Forecasting in Economics, Business, Finance and Beyond*. University of Pennsylvania.

Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. <https://doi.org/10.1080/07350015.1995.10524519>

Pesaran, H. H., & Shin, Y. (1998). Generalized impulse response analysis in linear multivariate models. *Economics Letters*, 58(1), 17–29. [https://doi.org/10.1016/S0165-1765\(97\)00214-0](https://doi.org/10.1016/S0165-1765(97)00214-0)

Diebold, F. X., & López, J. A. (1996). Forecast evaluation and combination. In G. S. Maddala & C. R. Rao (Eds.), *Handbook of Statistics* (Vol. 14, pp. 241–268). Elsevier.

Cumby, R. E., & Huizinga, J. (1992). Testing the autocorrelation structure of disturbances in ordinary least squares and instrumental variables regressions. *Econometrica*, 60(1), 185–195.

Dufour, J.-M. (1981). Rank tests for serial dependence. *Journal of Time Series Analysis*, 2(3), 221–233.

Mincer, J., & Zarnowitz, V. (1969). The evaluation of economic forecasts. In J. Mincer (Ed.), *Economic Forecasts and Expectations: Analysis of Forecasting Behavior and Performance* (pp. 1–46). National Bureau of Economic Research.

Pearson, K. (1895). Note on Regression and Inheritance in the Case of Two Parents. *Proceedings of the Royal Society of London*, 58, 240–242.